



САМАРСКИЙ УНИВЕРСИТЕТ
SAMARA UNIVERSITY

Анализ и прогнозирование оттока клиентов в сфере электронной коммерции с использованием методов машинного обучения

Работу выполнил
студент группы 6401-010302D
Бабошин Никита Андреевич.
Научный руководитель
Семенов Денис Анатольевич
доцент кафедры ИиВМ, к.ф.-м.н.

Самара 2026



Актуальность: прогнозирование оттока методами ML необходимо для оптимизации маркетинговых бюджетов и удержания клиентов в электронной коммерции [1].

Цель работы: разработать и экспериментально обосновать методологию прогнозирования оттока клиентов электронной коммерции на основе моделей машинного обучения.

Задачи:

- изучение теоретических основ анализа и прогнозирования оттока клиентов в сфере электронной коммерции;
- экспериментальное исследование моделей машинного обучения для прогнозирования оттока клиентов;
- разработка веб-приложения для поддержки принятия решений.

1. Gold, C. Fighting Churn with Data: The science and strategy of customer retention / Carl S. Gold. – Shelter Island : Manning Publications, 2020. – 504 p. – ISBN 978-1-61729-652-9.

Постановка задачи

Множество клиентов: $C = \{c_1, c_2, \dots, c_N\}$

Признаковое описание: $x_i \in \mathbb{R}^d$

Функция предсказания: $f: \mathbb{R}^d \rightarrow \{0, 1\}$

Целевая переменная:

$$y_i = \begin{cases} 1, & \text{если клиент } c_i \text{ склонен к оттоку (уходит)} \\ 0, & \text{если клиент } c_i \text{ остается лояльным} \end{cases}$$

Вероятностная формулировка:

$$p_i = P(y_i = 1 | x_i) = f(x_i), \quad p_i \in [0, 1]$$

Обучающая выборка: $\{(x_i, y_i)\}_{i=1}^N$

Два набора данных

1. Набор данных со статическими профилями клиентов – 5630 наблюдений [2]
2. Набор данных на основе логов маркетинговой платформы REES46 – 112610 наблюдений [3]




Рисунок 1 – Распределение клиентов по оттоку в первом наборе данных

Проблема: дисбаланс классов

2. Verma, A. Ecommerce Customer Churn Analysis and Prediction / ankitverma2010 // Kaggle : [сайт]. – 2020.

3. Fridrich, M. E-commerce churn dataset - REES46 / fridrichmrtn // Kaggle : [сайт]. – 2023.



ОПИСАНИЕ ПЕРВОГО НАБОРА ДАННЫХ

Признак	Описание
CustomerID	Уникальный идентификатор клиента
Tenure	Срок сотрудничества клиента с компанией
Gender	Пол клиента
CityTier	Категория города
Complain	Была ли подана жалоба в последний месяц
CouponUsed	Количество использованных купонов за последний месяц
OrderCount	Общее количество заказов, сделанных за последний месяц
MaritalStatus	Семейное положение клиента
SatisfactionScore	Оценка удовлетворённости клиента
Churn	Флаг оттока клиента

Признак	Описание
PreferredLoginDevice	Предпочитаемое устройство для входа
WarehouseToHome	Расстояние от склада до дома клиента
PreferredPaymentMode	Предпочитаемый способ оплаты клиента
NumberOfDeviceRegistered	Общее количество устройств клиента
PreferedOrderCat	Предпочитаемая категория заказов за последний месяц
NumberOfAddress	Общее количество адресов, добавленных для клиента
OrderAmountHikeFromlastYear	Процентное увеличение суммы заказов по сравнению с прошлым годом
DaySinceLastOrder	Количество дней с момента последнего заказа клиента
CashbackAmount	Средняя сумма кэшбэка за последний месяц
HourSpendOnApp	Количество часов, проведённых в приложении или на сайте



ПРЕДОБРАБОТКА ДАННЫХ




Рисунок 2 – Распределение клиентов по временным срезам до и после очистки и фильтрации второго набора данных

Признаки во втором наборе данных сгруппированы по RFM+ схеме

Основные этапы предобработки:

1. Очистка и фильтрация данных
2. Кодирование категориальных признаков
3. Масштабирование числовых признаков
4. Отбор признаков
5. Разделение данных

Разделение на обучающую и тестовую выборки в соотношении $\approx 80\%$ к 20%

Логистическая регрессия

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\omega_0 + \omega_1 X_1 + \dots + \omega_n X_n)}}$$

- Моделирует вероятность оттока (P)
- Коэффициенты ω показывают влияние каждого фактора

Дерево решений




Рисунок 3 – Пример визуализации дерева решений




Рисунок 4 – Схемы взаимодействия компонентов в ансамблях

Реализации: Random Forest, XGBoost

Интерпретация: встроенный метод `feature_importance_`, методы SHAP и LIME




Рисунок 5 – Архитектура MLP с регуляризацией




Рисунок 6 – Архитектура TabNet [4]




Рисунок 7 – Архитектура Logit Leaf Model [5]

Идея: дерево решений → сегменты → локальные логистические регрессии в листьях

Была написана **собственная реализация** алгоритма на Python

4. Arik, S. Ö. TabNet: Attentive Interpretable Tabular Learning / S. Ö. Arik, T. Pfister. – DOI: 10.1609/aaai.v35i8.16826 // Proceedings of the AAAI Conference on Artificial Intelligence. – 2021. – Vol. 35, Issue 8. – P. 6679–6687.

5. De Caigny, A. A new hybrid classification algorithm for customer churn prediction based on logistic regression and decision trees / A. De Caigny, K. Coussement, K. W. De Bock. – DOI: 10.1016/j.ejor.2018.02.009 // Europe-an Journal of Operational Research. – 2018. – Vol. 269, Issue 2. – P. 760–772.



Метрики оценки качества:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP},$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad \text{F1-Score} = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

- ROC-AUC – площадь под кривой зависимости TPR от FPR при варьировании порога классификации
- PR-AUC – площадь под кривой зависимости Precision от Recall при варьировании порога классификации

Эксперимент: Что ещё можно обучать в листьях?

Модель в листьях	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Логистическая регрессия	0,9094	0,8188	0,5947	0,6890	0,9077
Градиентный бустинг	0,9885	0,9683	0,9632	0,9657	0,9984

→ **Первый**
набор данных

Модель в листьях	Отбор признаков	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Логистическая регрессия	Нет	0,8631	0,9178	0,7218	0,8081	0,9458
	Есть	0,8673	0,9073	0,7436	0,8173	0,9426
Градиентный бустинг	Нет	0,8792	0,8618	0,8305	0,8458	0,9501
	Есть	0,8723	0,8202	0,8710	0,8449	0,9446

→ **Второй**
набор данных

Отбор: SelectKBest с оценкой по F-критерию Фишера (k=5)



Композитный показатель качества CQS (Composite Quality Score):

$$CQS = 0,4 \cdot F1\text{-Score}_{avg} + 0,3 \cdot PR\text{-AUC}_{avg} + 0,2 \cdot ROC\text{-AUC}_{avg} + 0,1 \cdot Accuracy_{avg}$$

Модель	F1-Score _{avg}	PR-AUC _{avg}	ROC-AUC _{avg}	Accuracy _{avg}	CQS
XGBoost	0,9086	0,9647	0,9737	0,9359	0,9412
GB Leaf Model	0,9053	0,9594	0,9737	0,9304	0,9377
Random Forest	0,8959	0,9598	0,9734	0,9292	0,9339
TabNet	0,8723	0,9410	0,9667	0,9186	0,9164
MLP	0,8334	0,9437	0,9642	0,8848	0,8978
Decision Tree	0,8444	0,8992	0,9188	0,8922	0,8805
Logit Leaf Model	0,7532	0,8433	0,9252	0,8884	0,8281
Logistic Regression	0,6697	0,7801	0,8955	0,7871	0,7597

Наилучшее качество прогнозов демонстрирует XGBoost, чуть уступают ему гибридный алгоритм GB Leaf Model и случайный лес.



ИНТЕРПРЕТАЦИЯ ПРОГНОЗОВ И ВЫЯВЛЕНИЕ ФАКТОРОВ ОТТОКА




Рисунок 8 – Объяснение ухода конкретного клиента




Рисунок 9 – Анализ важности по сегментам

Давность последнего взаимодействия
Интенсивность использования платформы
Финансовая активность
Товарные предпочтения
Дополнительные поведенческие метрики

	Встроенный метод XGBoost			Метод SHAP		
Группа	Среднее	Сумма	%	Среднее	Сумма	%
Recency	0,0036	0,0250	2,50	0,1645	1,1512	10,87
Frequency	0,0361	0,7952	79,51	0,3251	7,1528	67,56
Monetary	0,0041	0,0655	6,55	0,0525	0,8403	7,94
Preference	0,0032	0,0731	7,31	0,0308	0,7082	6,69
Others	0,0032	0,0413	4,13	0,0566	0,7356	6,95



```
graph LR; D1[Данные о клиентах] --> A0; D2[Информация о клиенте] --> A0; D3[Конфигурация приложения] --> A0; D4[Пользователь] --> A0; D5[Бизнес-правила анализа] --> A0; D6[Модель ML] --> A0; A0 --> R1[Результаты анализа]; A0 --> R2[Отчет об оттоке клиента];
```

Рисунок 10 – Контекстная диаграмма




Рисунок 11 – Декомпозиция контекстной диаграммы



В ходе работы были выполнены все поставленные задачи:

- ✓ Изучены теоретические основы анализа и прогнозирования оттока клиентов в сфере электронной коммерции.
- ✓ Проведено экспериментальное исследование моделей машинного обучения для прогнозирования оттока клиентов.
- Модель XGBoost показала лучший CQS, равный 0,9412.
- Замена логистической регрессии в листьях на градиентный бустинг в гибридном алгоритме улучшило качество прогнозирования на обоих наборах данных.
- Интерпретированы прогнозы и выявлены основные факторы, влияющие на отток клиентов.
- ✓ Разработано веб-приложения для поддержки принятия решений на основе лучшей модели.

Основные положения и результаты ВКР были апробированы в процессе участия в научно-практических конференциях, на одной из которых я занял II место. Одна статья по материалам исследования подана к печати в «Вестник молодых учёных и специалистов Самарского университета».



САМАРСКИЙ УНИВЕРСИТЕТ
SAMARA UNIVERSITY

**БЛАГОДАРЮ
ЗА ВНИМАНИЕ**